

Рубежный контроль №1 по ТМО

Афонин Иван ИУ5-62Б

Задача №1. Для заданного набора данных проведите корреляционный анализ. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Сделайте выводы о возможности построения моделей машинного обучения и о возможном вкладе признаков в модель. Для студентов групп ИУ5-62Б, ИУ5Ц-82Б - для произвольной колонки данных построить гистограмму.

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_wine
from scipy import stats

%matplotlib inline
plt.rcParams['figure.figsize'] = (10, 6)
sns.set_style("whitegrid")
```

```
In [2]: wine = load_wine()

df = pd.DataFrame(data=wine.data, columns=wine.feature_names)
df['target'] = wine.target

print("Размер датасета:", df.shape)
print("\nНазвания признаков:")
print(wine.feature_names)
print("\nНазвания классов:")
print(wine.target_names)
df.head()
```

Размер датасета: (178, 14)

Названия признаков:

['alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium', 'total_phenols', 'flavanoids', 'nonflavanoid_phenols', 'proanthocyanins', 'color_intensity', 'hue', 'od280/od315_of_diluted_wines', 'proline']

Названия классов:

['class_0' 'class_1' 'class_2']

Out[2]:

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavonoids
0	14.23	1.71	2.43	15.6	127.0	2.80	1.80
1	13.20	1.78	2.14	11.2	100.0	2.65	1.70
2	13.16	2.36	2.67	18.6	101.0	2.80	1.80
3	14.37	1.95	2.50	16.8	113.0	3.85	1.90
4	13.24	2.59	2.87	21.0	118.0	2.80	1.80

```
In [3]: print("Информация о пропусках в данных:")
print(df.isnull().sum())

print("\nОбщее количество пропусков:", df.isnull().sum().sum())

if df.isnull().sum().sum() > 0:
    print("\nОбнаружены пропуски! Удаляем строки с пропусками...")
    df = df.dropna(axis=0)
else:
    print("\nПропуски в данных отсутствуют. Обработка не требуется.")
```

Информация о пропусках в данных:

```
alcohol      0
malic_acid   0
ash          0
alcalinity_of_ash  0
magnesium    0
total_phenols 0
flavanoids   0
nonflavanoid_phenols 0
proanthocyanins 0
color_intensity 0
hue          0
od280/od315_of_diluted_wines 0
proline      0
target       0
dtype: int64
```

Общее количество пропусков: 0

Пропуски в данных отсутствуют. Обработка не требуется.

```
In [4]: print("Статистическое описание данных:")
df.describe()
```

Статистическое описание данных:

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_sulfur
count	178.000000	178.000000	178.000000	178.000000	178.000000	178.000000
mean	13.000618	2.336348	2.366517	19.494944	99.741573	1.055178
std	0.811827	1.117146	0.274344	3.339564	14.282484	0.236300
min	11.030000	0.740000	1.360000	10.600000	70.000000	0.700000
25%	12.362500	1.602500	2.210000	17.200000	88.000000	0.900000
50%	13.050000	1.865000	2.360000	19.500000	98.000000	1.000000
75%	13.677500	3.082500	2.557500	21.500000	107.000000	1.100000
max	14.830000	5.800000	3.230000	30.000000	162.000000	1.200000

```


In [5]: correlation_matrix = df.corr(method='pearson')

mask = np.triu(np.ones_like(correlation_matrix, dtype=bool))

plt.figure(figsize=(14, 12))
sns.heatmap(correlation_matrix,
            mask=mask,
            annot=True,
            fmt='.2f',
            cmap='coolwarm',
            center=0,
            square=True,
            linewidths=0.5,
            cbar_kws={"shrink": 0.8})

plt.title('Матрица корреляций признаков датасета Wine', fontsize=16, fontweight='bold')
plt.tight_layout()
plt.show()

```



```
In [6]: corr_pairs = []

for i in range(len(correlation_matrix.columns)):
    for j in range(i+1, len(correlation_matrix.columns)):
        corr_pairs.append({
            'Признак 1': correlation_matrix.columns[i],
            'Признак 2': correlation_matrix.columns[j],
            'Корреляция': correlation_matrix.iloc[i, j]
        })

corr_df = pd.DataFrame(corr_pairs)
corr_df = corr_df.sort_values('Корреляция', key=abs, ascending=False)

print("ТОП-10 наиболее сильных корреляций (по модулю):")
corr_df.head(10)
```

ТОП-10 наиболее сильных корреляций (по модулю):

Out[6]:

	Признак 1	Признак 2	Корреляция
55	total_phenols	flavanoids	0.864564
69	flavanoids	target	-0.847498
89	od280/od315_of_diluted_wines	target	-0.788230
67	flavanoids	od280/od315_of_diluted_wines	0.787194
62	total_phenols	target	-0.719163
60	total_phenols	od280/od315_of_diluted_wines	0.699949
64	flavanoids	proanthocyanins	0.652692
11	alcohol	proline	0.643720
90	proline	target	-0.633717
87	hue	target	-0.617369

```
In [7]: strong_corr_pairs = corr_df.head(5)

fig, axes = plt.subplots(2, 3, figsize=(15, 10))
axes = axes.ravel()

for idx, (_, row) in enumerate(strong_corr_pairs.iterrows()):
    if idx < 6:
        feature1 = row['Признак 1']
        feature2 = row['Признак 2']
        correlation = row['Корреляция']


        axes[idx].scatter(df[feature1], df[feature2], alpha=0.6, c=df['target'])
        axes[idx].set_xlabel(feature1, fontsize=10)
        axes[idx].set_ylabel(feature2, fontsize=10)
        axes[idx].set_title(f'Корреляция: {correlation:.2f}', fontsize=12, fontweight='bold')

        z = np.polyfit(df[feature1], df[feature2], 1)
        p = np.poly1d(z)
        axes[idx].plot(df[feature1].sort_values(), p(df[feature1].sort_values()),
                        "r--", alpha=0.8, linewidth=2)

if len(strong_corr_pairs) < 6:
    fig.delaxes(axes[len(strong_corr_pairs)])

plt.suptitle('Визуализация наиболее сильных корреляций между признаками',
             fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()
```


Визуализация наиболее сильных корреляций между признаками



```
In [8]: target_corr = correlation_matrix['target'].drop('target').sort_values(ascending=False)

plt.figure(figsize=(10, 8))
colors = ['red' if x < 0 else 'green' for x in target_corr.values]
target_corr.plot(kind='barh', color=colors)
plt.xlabel('Корреляция с целевой переменной (класс вина)', fontsize=12)
plt.title('Влияние признаков на класс вина', fontsize=14, fontweight='bold')
plt.axvline(x=0, color='black', linestyle='--', linewidth=0.5)
plt.grid(axis='x', alpha=0.3)
plt.tight_layout()
plt.show()

print("\nКорреляция признаков с целевой переменной:")
print(target_corr)
```




Корреляция признаков с целевой переменной:

alcalinity_of_ash	0.517859
nonflavanoid_phenols	0.489109
malic_acid	0.437776
color_intensity	0.265668
ash	-0.049643
magnesium	-0.209179
alcohol	-0.328222
proanthocyanins	-0.499130
hue	-0.617369
proline	-0.633717
total_phenols	-0.719163
od280/od315_of_diluted_wines	-0.788230
flavanoids	-0.847498

Name: target, dtype: float64

```
In [12]: selected_column = 'proline'

plt.figure(figsize=(10, 6))
plt.hist(df[selected_column], bins=20, edgecolor='black', alpha=0.7, color='red')
plt.xlabel(selected_column, fontsize=12)
plt.ylabel('Частота', fontsize=12)
plt.title(f'Гистограмма признака "{selected_column}"', fontsize=14, fontweight='bold')
plt.grid(axis='y', alpha=0.3)
plt.tight_layout()
plt.show()
```



Выводы:

Данный датасет не содержит пропусков, обладает небольшими размерами, что позволяет быстро обучать разные модели, классы сбалансированы. При этом в нём слишком большой разброс масштабов признаков, поэтому необходима нормализация или стандартизация, также присутствует мультиколлинеарность, что может оказывать негативное влияние. Таким образом, этому датасету лучше всего подойдут методы случайного леса или градиентного бустинга, также можно решать задачу логистической регрессии и k-ближайших соседей, но лучше не использовать его при решении задач линейной регрессии. Наиболее важными признаками являются flavanoids, proline, color_intensity, но они также сильно коррелируют друг с другом, поэтому нужно внимательно относиться к их выбору.

In []: